

專題摘要

非侵入式的腦機介面是透過量測腦波的 EEG 訊號解讀大腦的狀態，若是能發展出能即時將腦波訊號分類的模型，便能使肢體障礙的患者擁有和外界環境互動的機會。由於每個人的腦波數值差異大，以前都需要使用手刻的特徵並針對每個人調整模型參數，通用性低。人工智慧應用盛行的現今，已有許多學者嘗試將深度學習結合腦機介面，其中成效最佳的便是 CNN 模型。由於深度學習的 end-to-end 特性，我們能夠將原始資料直接送入模型分類，不再需要手動提取特徵。在我們這次的專題中，我們希望能將腦波儀即時量測的運動想像 EEG 資料串接到遠端的 CNN 模型，再輸出分類結果。

一、 關鍵詞

腦電圖(Electroencephalography/EEG)、腦機介面(Brain-Computer Interface/BCI)、即時(Real-Time)、運動想像(Motor Imagery)、深度學習(Deep Learning/DL)、卷積神經網路(Convolutional Neural Network/CNN)

二、 專題研究動機與目的

這個專題的發想原因，是由於我們覺得資訊技術結合生醫領域是未來趨勢，而且對人類腦袋的複雜運作感到有趣，才選擇分析腦波。在看了相關的應用之後，我們覺得腦機介面能夠幫助肢體障礙的患者，所以我們選擇此題目做研究。

三、 現有相關研究概況及比較

身心障礙者可能會需要輔助工具來協助他們運動、溝通及生活，這些工具一般都需要由肌肉或語言來進行控制。然而對於全身癱瘓的患者而言，這些常用的工具他們可能就無法使用。因此許多研究就開始專注於是否能透過侵入性/非侵入性方法量測腦波訊號，並提供新的輔助工具—腦機介面系統。科學家們希望透過這樣的系統獲取腦部活動的特徵，並將他們轉譯成機器能解讀的訊號[1]。而運動想像是指沒有實際的肢體行為，利用大腦意念想像肢體動作。由於其無須外部刺激，只需要人進行想像，就能得到特定的腦波，是相對簡單、安全和低成本的方法，且又能透過 EEG 這種非侵入性的電生理監測方法量測腦電波訊號，因此在腦機介面中有廣泛的運用[2] [3]。

傳統的機器學習上，常以共同空間模式(CSP)來對二分類運動想像的腦波訊號提取特徵[4]。雖然這樣的特徵提取方法已能使後續的分類器有不錯的分類結果，但通常這些方法都仰賴科學家取出手刻的特徵[2] [3] [5]。對於易有受試者間差異的 EEG 訊號而言，人工提取這些特徵是一件困難的事，這是造成以傳統機器學習方法來分類腦波訊號的準確率停滯不前的主因。隨著近年深度學習的不斷發展，由於深度學習的 end-to-end 特性，特徵提取的步驟已融合到深度學習演算法中，不再需要人工實現，因此許多常見的深度學習模型如 CNN[6] [7]、RNN[8] [9]等相繼被運用於運動想像的腦波分類。[10]中使用了他們所收集的資料比較了幾種深度學習模型的表現，其中 deep CNN(dCNN)模型的準確率最好，然而它因層數多、參數多，用在即時的腦波分類上延遲較多，而 pragmatic CNN(pCNN)模型準確率次高且為較輕量的深度學習模型，用在即時的腦波分類上延遲較少，因此我們的專題中決定重現[10]中的 pCNN 模型並應用於我們自己的即時腦機介面系統中。


四、團隊合作方式

由於我們兩位組員是室友關係，因此我們的專題合作方式皆為在房間一起討論、一起實作的形式。每周會與教授開一次會，討論專題的內容、方向以及遇到的問題等。而在我們的 EEG 實驗中，則是由成同學擔任施測者、劉同學擔任受測者。


五、設計原理、研究方法與步驟


1. Offline Training 資料收集

我們首先透過 E-Prime 3.0 這個實驗研究軟體設計及撰寫我們的 EEG 實驗流程。受試者在我們的實驗中將會進行一系列的運動想像，包含想像左手運動及右手運動。所有的實驗過程及操作都在工三的 546 實驗室進行。為了避免受測者長時間不停想像導致疲憊，我們每次的實驗 session 會分為 3 個約 6 分鐘左右的 run 來進行，各個 run 之間受測者有 10 分鐘的時間能夠充分休息。每一個 run 包含了 40 個（左手、右手各 20 個）運動想像任務，每個 8.5 秒鐘。每個運動想像任務的前 3 秒鐘，受試者注視的電腦螢幕中間會出現十字，目的是希望受測者能將目光聚集在十字上，不要出現目光飄移的情況影響腦波。接著螢幕中央會出現持續 1 秒的向左或向右的箭頭，提示受測者將要執行左手還是右手的運動想像。接下來的 3 秒鐘，受測者會進行運動想像，這三秒鐘運動想像的腦波將會被使用於我們的模型中進行分類。想像結束後，受測者會有 1.5 秒的時間短暫休息，然後繼續下一個運動想像任務。運動想像任務流程如圖一所示[11]。



圖二為我們做實驗的照片。我們的腦波訊號使用 BrainVision Recorder 這個軟體來記錄，並使用 500Hz 的取樣頻率，電極配置則依照 Standard 64Ch actiCAP snap 的 Green Holders (Label 1~32)，如圖三所示。雖然我們紀錄了 31 個電極，但實際上在我們的分類模型中，我們只使用其中的三個電極，分別為 C3、Cz 和 C4。





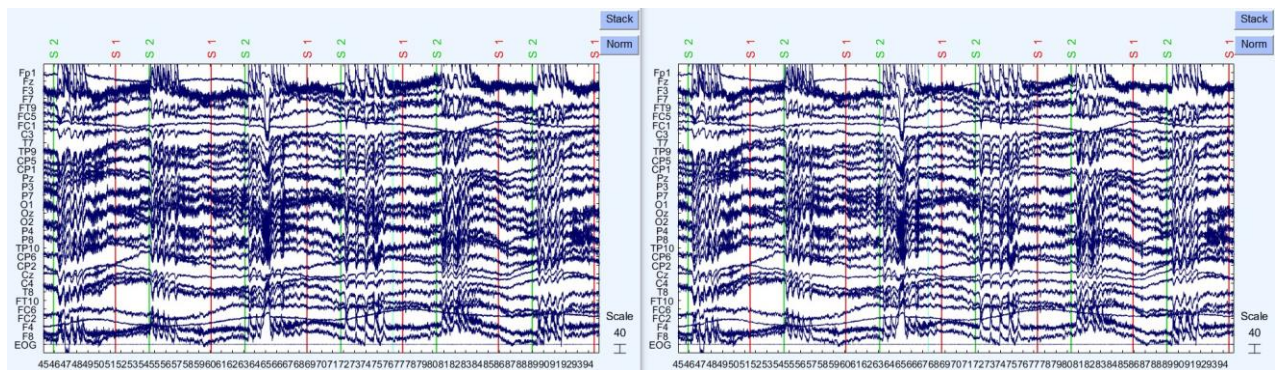
2. Offline Training 資料前處理

要用在 offline training 上所收集的腦波資料，我們會使用 Python 的 MNE package 來做前處理。首先，我們將資料的取樣頻率由原本的 500Hz 降低到 250Hz，因為 250Hz 是我們所參考的 paper[10]中所使用的取樣頻率，同時降低取樣頻率也能夠平滑腦波資料，減少一些雜訊。

接著，我們進行重參考(re-reference)，將所有電極的資料平均值做為新的參考值(common average reference)，再把所有電極的資料都減去此參考值。雖然原本在收集資料時，儀器內部已經利用 FCz 電極作為 online reference，用來消除電極共有的雜訊，但在這裡採取以平均值做為新的參考值(offline reference)，能再讓所有電極有一個共同的基準。

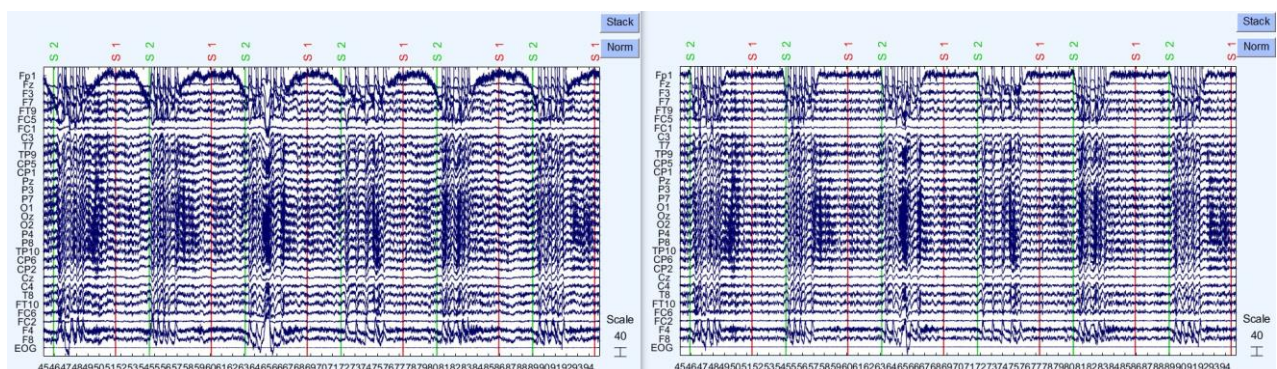
做完重參考之後，我們會將模型訓練時不需用到的電極資料拿掉，只留下 C3、Cz 和 C4 三個電極的資料，接下來的資料前處理步驟都是在這三個電極的資料上做。

再來，我們使用 3 個濾波器來做濾波，第一個是濾除 60Hz 訊號的點阻濾波器(notch filter)，用來消除交流電造成的干擾；第二個是截止頻率為 0.5Hz 的高通濾波器(high-pass filter)，用來消除低頻雜訊產生的基線漂移(baseline drift)；最後一個是留下 2~40Hz 的帶通濾波器(band-pass filter)。選擇這個頻率範圍的原因是因為現在腦科學家能解讀的大約是 50Hz 以下的腦波[12]，在許多運動想像的實驗中，也都是採取這個頻段的腦波來做分析[13] [14]。圖四中能夠看出各個濾波器作用後的結果。



(a) 原始資料(raw data)

(b) 經點阻濾波器濾除 60Hz 訊號




(c) 再經高通濾波器濾除 0.5Hz 以下的訊號

(d) 最後經帶通濾波器留下 2~40Hz 的訊號

圖四

圖(a)至圖(d)依序是資料的濾波過程，明顯可見的是經高通濾波器移除低頻雜訊後，資料整齊很多。

再來，我們針對截取出的每段運動想像資料(epochs)進行基線校正(baseline correction)。在做完重參考和濾波後，我們已經消除了一些訊號中的雜訊，但此時我們的訊號並不是 zero-mean，可能每個（電極）channel 都還各有自己的 offset，所以我們會利用運動想像開始前的 0.1~0.5 秒鐘（如圖五中第 3.5~3.9 秒的綠色區域所示），計算出這段時間各個 channel 的平均值，然後當次 epoch 各個 channel 的腦波數值就會分別減去它們所對應 channel 的平均值，希望能讓每個 channel 的腦波都能是 zero-mean。



最後，我們一樣針對截取出的每個 epoch 資料做正規化(normalization)。我們計算出所有 channel 在此運動想像期間的一個共同的平均值和標準差，然後做 z 分數標準化(z-score standardization)，式子如圖六所示。我們不是分別對所有 channel 都計算出平均值及標準差，然後每個 channel 各自利用它們所算出的平均值及標準差做標準化，而是只幫所有 channel 計算

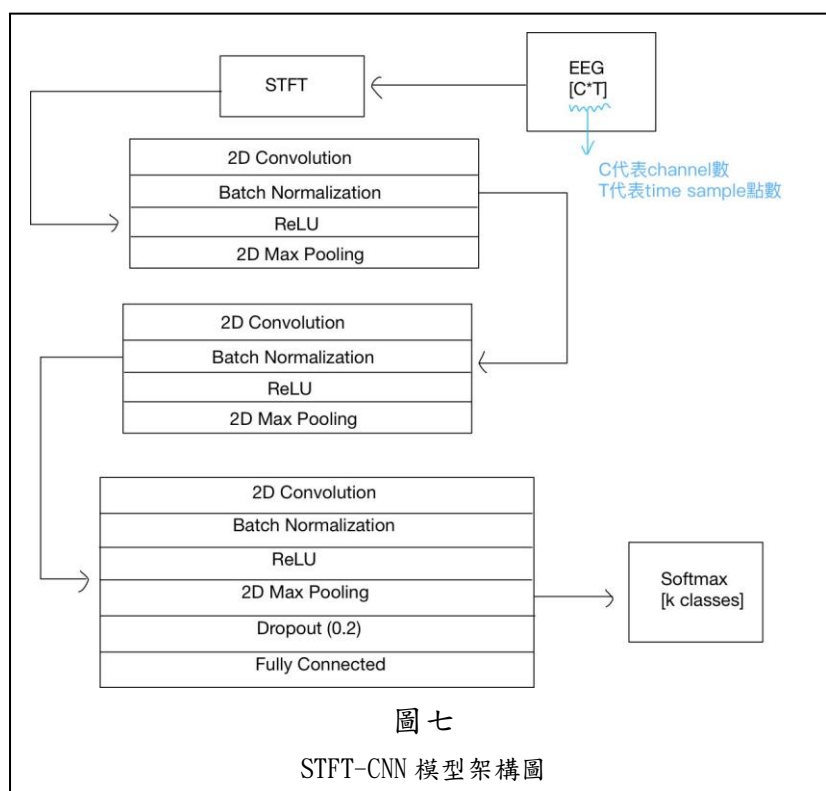
出一個平均值及標準差的原因，是因為我們的運動想像任務是想像左手及右手運動。理論上想像左手時，右腦的腦波活動會比較強烈，而想像右手時，左腦的腦波活動會比較強烈。若每個 channel 各自計算平均值及標準差做標準化，會使得這種左右腦的腦波活動差異特徵消失。

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

圖六
z 分數標準化的式子

3. STFT-CNN 模型

我們使用了 Zied Tayeb 等人所提出的 pCNN 模型，我們在此稱它為 STFT-CNN 模型 [10]。此模型分成兩個主要的部份，分別是 STFT 和 pCNN(pragmatic CNN)這兩個部分。首先，利用短時距傅立葉轉換(short-time Fourier transform/STFT)將輸入的 EEG 訊號由時間序列資料轉變成以影像方式呈現的時頻譜(spectrogram)。接著，計算出來的時頻譜會傳入 pCNN 模型中。此模型中包含了 3 個卷積區塊(convolutional block)和一個全連結層(fully connected layer)。每個卷積區塊中含有一個卷積層(convolutional layer)，然後加上批量標準化(batch normalization)來減輕 covariate shift 的問題，讓我們的模型能更穩健。接著會用 ReLU 來作為激勵函數(activation function)。最後則是加上一個最大池化層(max-pooling layer)來減少參數數量。全連結層中則是用歸一化指數函數(softmax)作為激勵函數，用來計算此筆輸入資料分別屬於每個分類類別的機率。模型的架構圖如圖七所示。



六、系統實現與實驗

1. 模型驗證—BCI Competition IV Dataset 2b

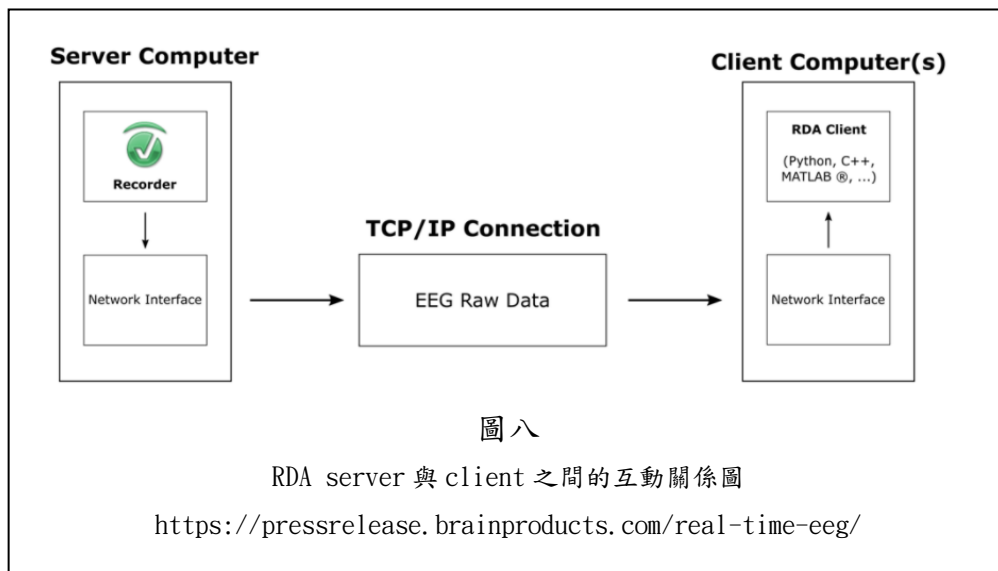
為了測試我們模型的效果，我們先使用了 BCI Competition IV Dataset 2b[11]當作訓練資料和驗證資料。這是一份紀錄左手和右手運動想像的資料集，九位受測者的腦波資料以 3 個 EEG 電極(C3、Cz 和 C4)和 3 個 EOG 電極來記錄，每位受測者皆紀錄了 360 筆有標籤的資料(左右手各 180 筆)，我們自己的實驗流程以及使用於分類的電極都參考了這份資料集的作法。前處理的方法如同前述 offline training 的方法。將這份資料集前處理後，將有標籤的資料用 holdout validation 的方法以 9:1 分出訓練資料和驗證資料，送入我們所建立的 STFT-CNN 模型訓練及測試後，我們得到了大約 65%的驗證資料準確率，說明我們的模型有一定的可行性與可靠度。

2. 模型正式訓練—Offline Data


在確認了我們模型的可行性後，我們使用 offline 收集的腦波資料重新訓練我們的 STFT-CNN 模型。我們使用 Adam 來優化我們的模型，並用 holdout validation 的方法以 9:1 分出訓練資料和驗證資料。我們在第 50 個 train epoch 時將訓練好的模型儲存起來，以用在下一階段的系統測試。

3. 系統測試—Online Data

在進行系統測試時，如同前述，我們使用 BrainVision Recorder 這個軟體來記錄腦波資料，並使用 500Hz 的取樣頻率，電極配置則依照 Standard 64Ch actiCAP snap 的 Green Holders (Label 1~32)。我們會將收集到的資料由 BrainVision Recorder 所在的電腦(作為 Remote Data Access/RDA server)即時透過 TCP/IP 傳送到另一台 STFT-CNN 模型所在的遠端電腦(作為 RDA client)，如同圖八所示。根據 BrainVision Recorder 的官方文件[15]，每一次透過 TCP/IP 傳送的封包，前 24 個 byte 為 header，裡面記載了這個封包的總長度，以及這個封包的種類。我們的封包總共分成 3 個種類，第一種是開始連線的封包，第二種是用來傳送腦波訊號的封包，最後一種則是結束連線的封包。

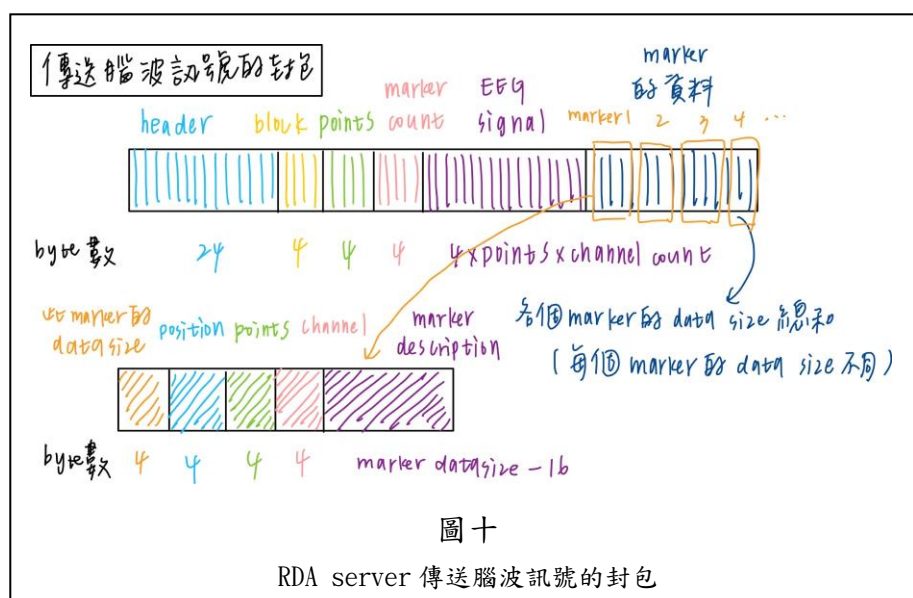



首先當我們的 RDA client 連上 RDA server 時，server 會傳送如圖九所示的封包給 client。裡面會告訴 client 腦波訊號由幾個電極來記錄(channel count)、取樣的時間間隔(sampling interval，也就是取樣頻率的倒數)、資料解析度(resolution，是每個電極資料的縮放倍數，因為每個電極連接頭皮之間導電膠的電阻值不同，因此之後 RDA client 收到的訊號必須根據電極乘上這裡的縮放倍數才能還原真正的腦波數值)和各個電極的名字(channel name)。



之後 RDA server 則會傳送如圖十所示的封包，開始傳送腦波資料給 client。封包裡面紀錄了這是第幾個封包(block，可用來判斷 overflow)、這次傳送過來的腦波資料包含了幾個取樣點的資料(points，基本上這個數量都是 10)、資料標記的數量(marker count，告訴 client 這次傳過來的資料中有多少個 trigger 存在)以及腦波訊號的資料及標記的資料。標記的資料中會記錄這個標記是觸發在哪一個取樣點上，以及其所作用的電極(基本上我們作用的電極都是全部電極)。因為我們在運動想像(epoch)的開始/結束及基線校正時段的開始/結束時都會送不同的標記，如圖十一所示。所以根據封包中的標記數量和標記資料，RDA client 就能知道運動想像及基線校正時段是何時開始與結束，就能順利拿到這些時段的腦波資料。而且在運動想像開始的時候，我們會根據這次的運動想像任務是左手還是右手的運動想像傳送不同的標記，因此 client 透過標記也能得知這個 epoch 的真實分類。每當 RDA Client 收到一次 epoch 的運動想像資料及基線校正資料後，就會執行和 offline 資料相同的前處理，接著送進我們上一個階段訓練完成的 STFT-CNN 模型中，得到模型所預測出的分類。最後我們會在螢幕上顯示這筆資料的真實分類及模型對這筆資料所預測的分類。


而當我們結束腦波紀錄時，RDA server 會傳送結束連線的封包，client 收到後就會結束連線。






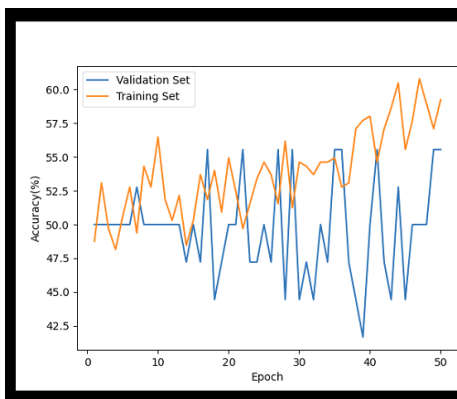
七、效能評估與成果

我們以 BCI Competition IV Dataset 2b[11]為訓練及驗證資料的實驗結果如圖十二所示。從中可以看到我們的系統使用於 BCI Competition IV Dataset 2b 大約有 65%的驗證資料準確率。從混淆矩陣(confusion matrix)中也能看出我們的模型基本上有預測出正確的結果。我們也計算了受測者進行運動想像時的腦波訊號功率，並以拓樸圖的方式視覺化出來，從中可以看出各個受測者進行左右手運動想像時腦訊號強度的不同，結果如圖十三所示。由於人腦是對側控制—左腦控制右半邊的身體，而右腦控制左半邊的身體，所以理論上當受測者在進行左手的運動想像時，右腦的活動應該較強烈。然而圖中所顯示的腦訊號強度和預想中的並不太相同，反而看起來是想像左手運動時，左腦活動較強烈，而想像右手運動時，右腦活動較強烈。即使如此，仍能看出受測者在進行左手和右手運動想像時腦波的不同。

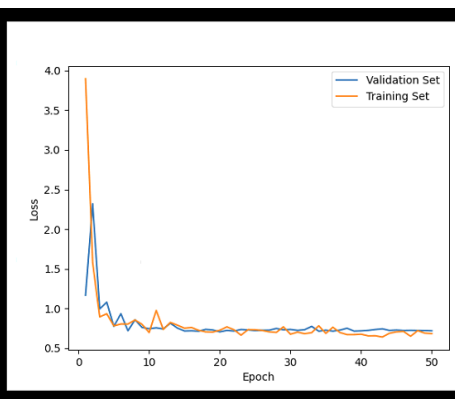




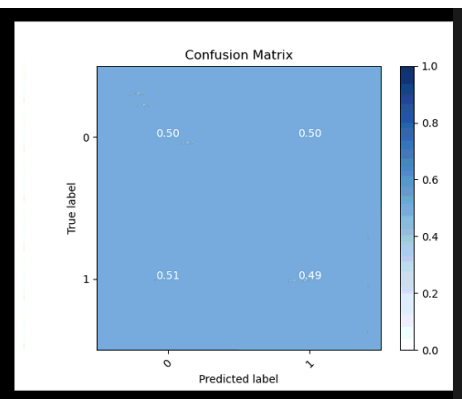
而以我們自己收集的腦波資料訓練及驗證模型的實驗結果如圖十四所示。由於我們用來驗證模型訓練成果的資料筆數較少，為了避免分類準確率受資料中類別分布數量影響太大，我們讓驗證資料中左手和右手的資料筆數一樣多。然而不論我們怎麼調整訓練參數，我們的模型準確率皆為 50%，看起來總是預測得非常隨機。而我們所收集的腦波資料拓模圖如圖十五所示，仍然和預想中的不相同，但這次就連左右手運動想像的腦波分布也看不出明顯的差別。



(a) 準確率



(b) 損失




(c) 混淆矩陣


圖十四

以我們自己收集的腦波資料訓練及驗證模型的結果


1006 WenHsin's Left Hand Imagery




1006 WenHsin's Right Hand Imagery




1006 WenHsin's Left Hand Imagery




1006 WenHsin's Right Hand Imagery




1013 WenHsin's Left Hand Imagery




1013 WenHsin's Right Hand Imagery




1013 WenHsin's Left Hand Imagery




1013 WenHsin's Right Hand Imagery




1027 WenHsin's Left Hand Imagery




1027 WenHsin's Right Hand Imagery



1027 WenHsin's Left Hand Imagery



1027 WenHsin's Right Hand Imagery



(a)只留下模型所使用的 C3、Cz 及 C4 電極

(b)我們有紀錄的 31 個電極

圖十五

我們的受測者在不同天進行左右手運動想像時的腦波功率拓模圖


我們的系統測試結果如圖十六、十七所示。我們會在螢幕上印出每次運動想像任務的真實分類以及由我們的模型預測出的分類，如同圖十六所示。等到此 session 的所有任務都進行完成之後，我們會印出這次 session 預測的準確率以及混淆矩陣，如同圖十七所示。由準確率以及混淆矩陣可以看出我們的模型對於我們的輸入皆預測為 1(右手)，且因為我們的輸入是剛好一半左手、一半右手，因此準確率剛好為 50%。圖十八則為系統測試的腦波資料拓模圖。我們的實驗 demo 影片可以在 <https://youtu.be/NLCQ1K1psvk> 觀看。

```
=====
Trial index: 8
Truth: 0
Predict: 1
=====
/home/bsplab/Desktop/project/RDA_classification.py:74: RuntimeWarning: filter_length (413)
is longer than the signal (100), distortion is likely. Reduce filter length or filter a lon
ger signal.
baseline = mne.filter.filter_data(baseline, sfreq=250, l_freq=2, h_freq=40, verbose='warn
ing')
=====
Trial index: 9
Truth: 0
Predict: 1
=====
/home/bsplab/Desktop/project/RDA_classification.py:74: RuntimeWarning: filter_length (413)
is longer than the signal (100), distortion is likely. Reduce filter length or filter a lon
ger signal.
baseline = mne.filter.filter_data(baseline, sfreq=250, l_freq=2, h_freq=40, verbose='warn
ing')
=====
Trial index: 10
Truth: 1
Predict: 1
=====
```

圖十六

在螢幕上印出的每次的真實分類及預測分類


Confusion Matrix



Stop Recording
Accuracy: 50.0

圖十七

系統測試的混淆矩陣及準確率



八、討論

由我們的實驗結果可看出我們的系統應用在我們自己所收集的資料上還有很大進步的空間。由於我們使用於 BCI Competition IV Dataset 2b 及自己的資料上的模型架構是完全相同的，我們認為導致我們的模型沒有訓練成功的可能原因可能是我們所收集的資料。要應用於腦波分類的腦波資料，最主要需要在兩個類別上有所不同。即使圖十三 BCI Competition IV Dataset 2b 的拓模圖和預想中的不盡相同，但我們仍能看出他們在不同類別上的差異，可能這就是其能夠訓練起來的原因。而我們所收集的腦波，因為受測者是我們自己的組員，並沒有接受過運動想像的訓練，所以可能我們的受測者在想像左右手時並沒有很有區別，導致兩者的腦波沒有明顯的差異。或者也可能是因為我們的資料筆數並沒有很多，種種原因導致我們的模型在訓練時無法找出他們的不同並學習，從而使得訓練後的驗證結果看起來非常隨機。由於腦波在不同人之間的變異(inter-subject variation)是非常大的[16]，意即每位受測者即使都是執行左手和右手的運動想像，但每位受測者所想像而量測到的腦波都是不太一樣的，這點可以從圖十一的拓模圖中看出來。而且即使是同一位受測者想像同一個動作，他的腦波也會隨著其情緒、環境等有所不同，因此不同天所收集的腦波也可能會有很大的不同(intra-subject variation)[16]。雖然我們自己收集的資料都是來自於同一位受測者，然而因為收集的資料來自不同的日期，因此圖十五及圖十八的拓模圖中反映出了這種 intra-subject 變異大的特性。我們認為系統測試時我們的模型皆預測同一個分類的原因，可能就是由於這種 intra-subject 變異，我們進行系統測試的那天所收集的腦波，和先前我們所收集來訓練模型的腦波分佈不太相同，才導致系統測試時我們的模型皆預測同一個分類。

九、結論

雖然我們的實驗結果在準確率上並沒有突出的表現，但我們的系統並沒有很長的延遲時間，是我們的優點。未來我們希望能找不同的受試者來參與我們的實驗，讓我們的系統能更 general，也希望能增加我們系統的分類數量，讓系統的可應用範圍能更廣泛，並且也希望未來能基於我們的系統開發實際的應用。這次的專題對我們來說是認識深度學習領域的初次經驗，不僅是理論方面，在實作方面我們都學到了很多，是一份珍貴的經驗，很謝謝一直以來幫助我們的教授。

十、參考文獻

- [1] Schalk, Gerwin, et al. "BCI2000: a general-purpose brain-computer interface (BCI) system." *IEEE Transactions on biomedical engineering* 51.6 (2004): 1034-1043.
- [2] Coyle, Damien, et al. "EEG-based continuous control of a game using a 3 channel motor imagery BCI: BCI game." *2011 IEEE Symposium on Computational Intelligence, Cognitive Algorithms, Mind, and Brain (CCMB)*. IEEE, 2011.
- [3] Li, Ting, et al. "Development of a novel motor imagery control technique and application in a gaming environment." *Computational intelligence and neuroscience* 2017 (2017).
- [4] Ang, Kai Keng, et al. "Filter bank common spatial pattern (FBCSP) in brain-computer interface." *2008 IEEE international joint conference on neural networks (IEEE world congress on computational intelligence)*. IEEE, 2008.
- [5] Tangermann, Michael, et al. "Playing pinball with non-invasive BCI." *NIPS*. 2008.
- [6] Chaudhary, Shalu, et al. "Convolutional neural network based approach towards motor imagery tasks EEG signals classification." *IEEE Sensors Journal* 19.12 (2019): 4494-4500.
- [7] Tang, Zhichuan, Chao Li, and Shouqian Sun. "Single-trial EEG classification of motor imagery using deep convolutional neural networks." *Optik* 130 (2017): 11-18.
- [8] Luo, Tian-jian, Chang-le Zhou, and Fei Chao. "Exploring spatial-frequency-sequential relationships for motor imagery classification with recurrent neural network." *BMC bioinformatics* 19.1 (2018): 1-18.
- [9] Wang, Ping, et al. "LSTM-based EEG classification in motor imagery tasks." *IEEE transactions on neural systems and rehabilitation engineering* 26.11 (2018): 2086-2095.
- [10] Tayeb, Zied, et al. "Validating deep neural networks for online decoding of motor imagery movements from EEG signals." *Sensors* 19.1 (2019): 210.
- [11] Leeb, R., et al. "BCI Competition 2008 - Graz data set B." *Graz University of Technology, Austria* (2008): 1-6.
- [12] Pfurtscheller, Gert, Doris Flotzinger, and Christa Neuper. "Differentiation between finger, toe and tongue movement in man based on 40 Hz EEG." *Electroencephalography and clinical neurophysiology* 90.6 (1994): 456-460.

[13] Ince, Nuri F., Ahmed H. Tewfik, and Sami Arica. "A Space-Time-Frequency analysis approach for the classification motor imagery EEG recordings in a Brain Computer Interface task." *2006 International Conference of the IEEE Engineering in Medicine and Biology Society*. IEEE, 2006.

[14] Dũng, Phạm Tiến, et al. "EEG Signals For Authentication In Security Systems." *Nghiên cứu Khoa học và Công nghệ trong lĩnh vực An toàn thông tin* 2.03 (2016): 17-32.

[15] Brain Products. (September 30, 2013). Retrieved from http://sites.bu.edu/reinhartlab/files/2017/06/BrainVision_Recorder_UM-1.pdf.

[16] Saha, Simanto, and Mathias Baumert. "Intra-and inter-subject variability in EEG-based sensorimotor brain computer interface: a review." *Frontiers in computational neuroscience* 13 (2020): 87.